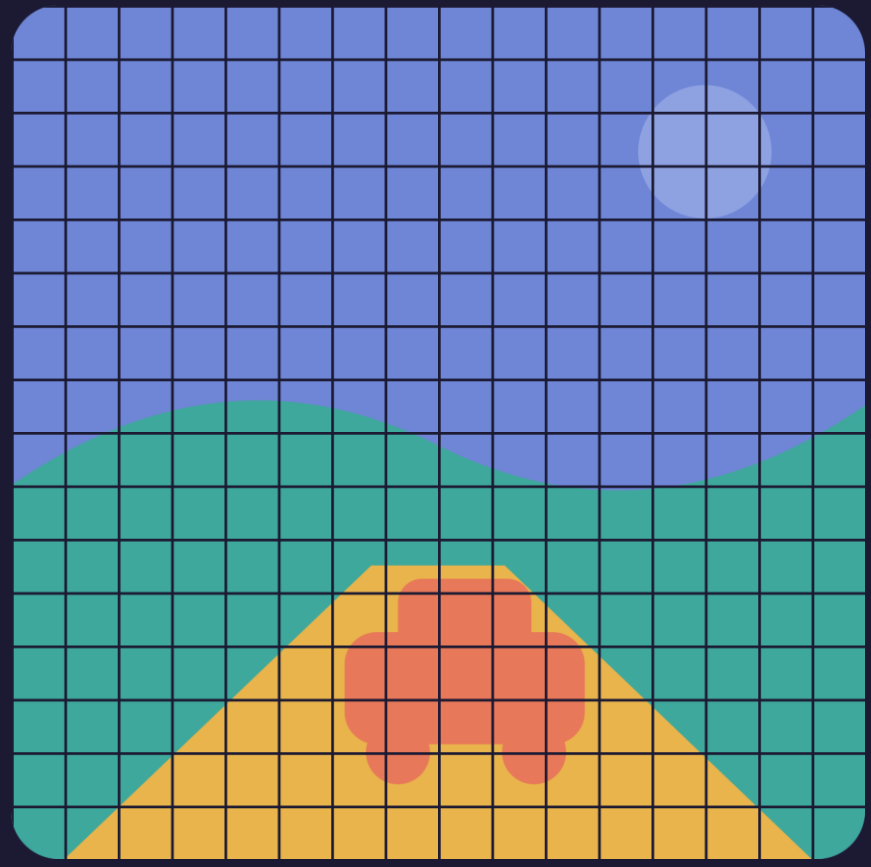
ОСНОВЫ КОМПЬЮТЕРНОГО ЗРЕНИЯ

Семантическая сегментация

Как архитектура U-Net разделяет изображение по пикселям

Рихельгоф Владимир
Якимов Сергей
АА-23-07



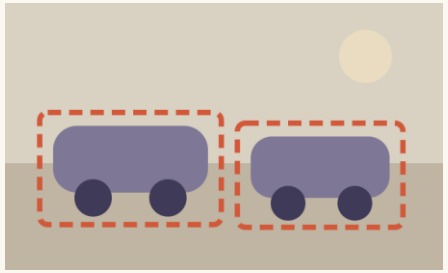
02 · ЧЕТЫРЕ ЗАДАЧИ

Что умеет компьютерное зрение



Классификация

Одна метка на весь снимок: «здесь есть машина»



Детекция

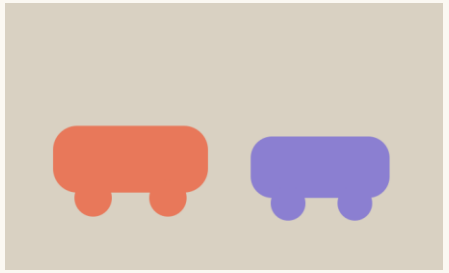
Рамка вокруг каждого объекта: «машина вот здесь»



Семантическая сегментация

Класс для каждого пикселя: небо, дорога, машина

наша тема



Экземплярная сегментация

Класс и номер объекта: машина №1, машина №2

Семантическая сегментация не различает отдельные объекты одного класса: обе машины для неё — просто «машина».

03 · МАСШТАБ ЗАДАЧИ

Решение — для каждого пикселя

Сеть ставит не одну метку на картинку, а принимает отдельное решение для каждой точки. Чем больше снимок, тем больше решений.

Изображение	Пикселей = решений	Где встречается
28×28	784	рукописная цифра (MNIST)
512×512	262 144	снимок клеток из статьи U-Net
1920×1080	2 073 600	кадр видео Full HD
2048×1024	2 097 152	кадр городской съёмки Cityscapes

≈1,5 ч

уходит у человека на ручную разметку одного кадра Cityscapes — пиксель за пикселем

19

классов различают на кадрах Cityscapes: дорога, тротуар, человек, машина, небо…

Как компьютер «видит» картинку

212	208	205	210	214
207	64	58	71	209
203	55	41	60	206
209	68	52	66	211
215	210	204	208	213

Вход: яркость пикселей, от 0 (чёрный) до 255 (белый)



0	0	0	0	0
0	1	1	1	0
0	1	1	1	0
0	1	1	1	0
0	0	0	0	0

Выход: номер класса, 0 — фон, 1 — клетка

Цветной снимок — это три такие таблицы (красный, зелёный, синий). Снимок 512×512 — это **786 432 числа** на входе.

05 · ГЛАВНАЯ ПРОБЛЕМА

Чтобы понять «что», сеть сжимает картинку. Но при сжатии теряется «где».

Что на снимке?

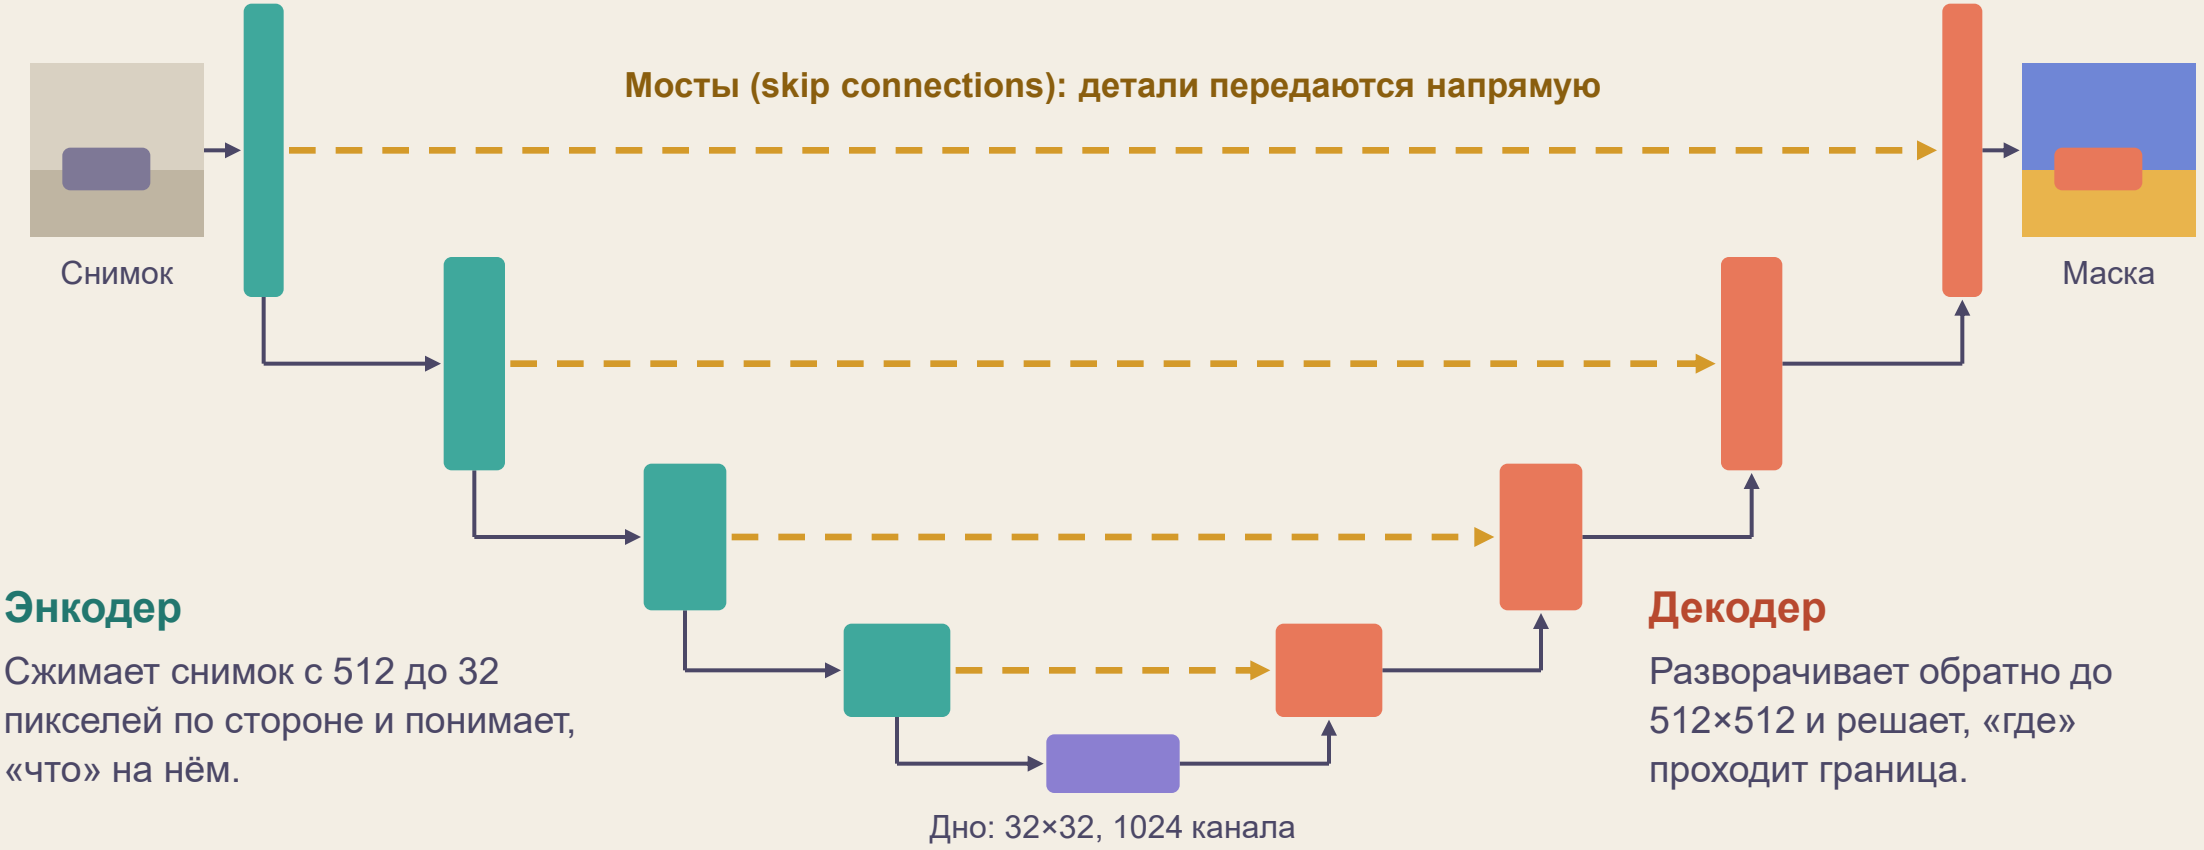
Нужен широкий взгляд: картинку уменьшают, и сеть видит объект целиком, а не отдельные точки.

Где именно граница?

Нужны мелкие детали исходного размера: каждый пиксель должен остаться на своём месте.

U-Net решает обе задачи сразу — за счёт симметричной формы и «мостов» между половинами.

U-Net: сеть в форме буквы U



Энкодер

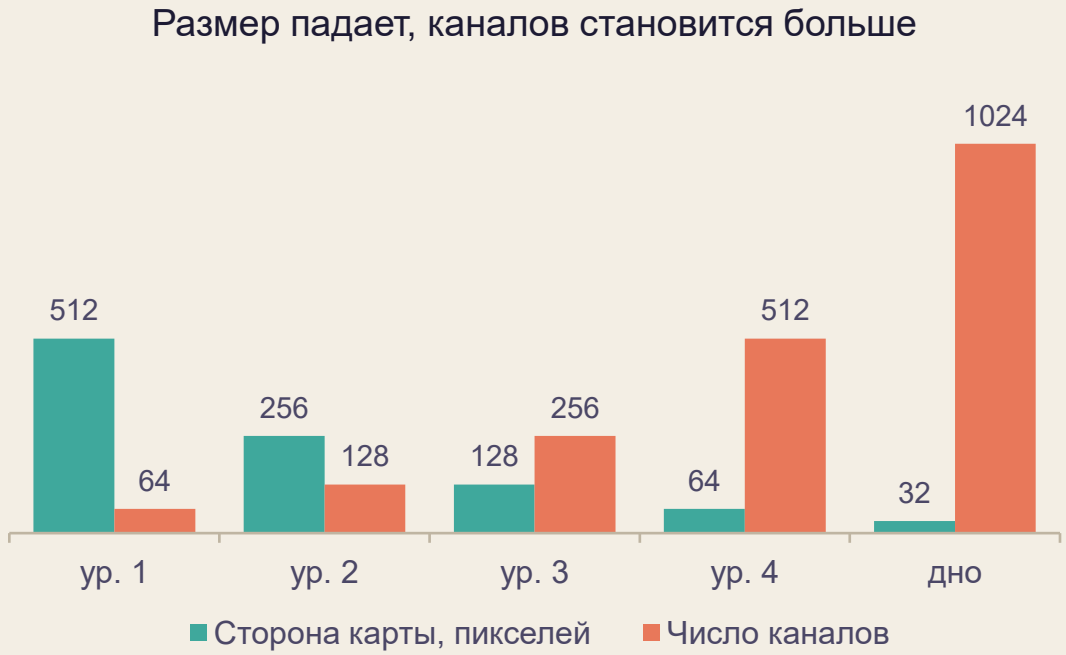
Сжимает снимок с 512 до 32 пикселей по стороне и понимает, «что» на нём.

Декодер

Разворачивает обратно до 512×512 и решает, «где» проходит граница.

Меньше пикселей — больше смысла

Уровень	Размер	Каналов	Что «видит»
1	512×512	64	края, пятна цвета
2	256×256	128	углы, текстуры
3	128×128	256	части объектов
4	64×64	512	крупные части
дно	32×32	1024	«что это за объект»



Шаг вниз — **max-pooling**: из квадрата 2×2 остаётся одно, самое сильное значение. Площадь карты падает в 4 раза, а число каналов — «детекторов признаков» — удваивается.

Вернуть размер и чёткие границы

ШАГ 1

Увеличить

Обратная свёртка 2×2 удваивает карту: 32 → 64 → 128 → 256 → 512.

ШАГ 2

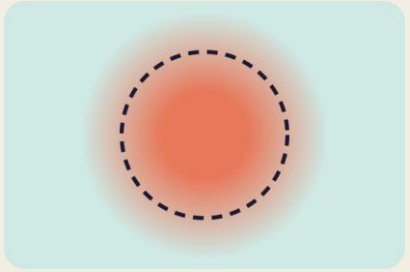
Склеить

По мосту приходит копия из энкодера того же размера: «смысл» снизу + детали сверху.

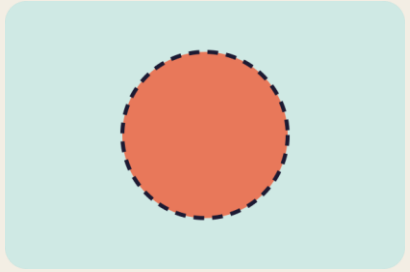
ШАГ 3

Выбрать класс

Свёртка 1×1 даёт каждому пикселю вероятности классов. Побеждает наибольшая.



Без мостов: граница «плывёт»



С мостами: граница чёткая

ПИКСЕЛЬ (120, 45)

дорога 0,91 · машина 0,06 · небо 0,03

→ **ответ: «дорога»**

09 · ОБУЧЕНИЕ

Как учиться на малых данных

30

размеченных снимков 512×512 хватило авторам U-Net в 2015 году

Обучение заняло около 10 часов на одной видеокарте NVIDIA Titan (6 ГБ)

Аугментации

Снимки поворачивают, сдвигают и «мнут» упругими деформациями — из 30 примеров получаются тысячи.

Ошибка по пикселям

Каждый пиксель сравнивают с разметкой (кросс-энтропия): чем увереннее сеть ошиблась, тем больше штраф.

Вес границ

Тонким границам между соседними клетками дают больший вес, чтобы клетки не «слипались».

Где работает U-Net сегодня

Медицина

Опухоли и органы на КТ и МРТ, клетки на снимках микроскопа.

nnU-Net (2021) проверена на 23 наборах медданных

Беспилотники

Где дорога, тротуар, пешеход и машина — на каждом кадре камеры.

Cityscapes: 5000 кадров с точной разметкой

Спутники и поля

Контуры зданий, полей, лесов и вырубок на снимках из космоса.

большие снимки режут на квадраты-тайлы

Генерация картинок

В Stable Diffusion (2022) именно U-Net шаг за шагом убирает шум, превращая его в изображение.

та же форма «U» и те же мосты